YAPAY ZEKÂ VE ADALET EĞİTİMİ · HAFTA 4

Veri: Yapay Zekânın Öğrendiği Her Şey

BU HAFTA

Veriye yakından bakıyoruz

İlk haftalarda "yapay zekâ örneklerden öğrenir" demiştik. Bu haftanın konusu, o örneklerin kendisi: veri.

Üç soruyu cevaplayacağız: Bir model neye bakar? "Öğrenmek" burada tam olarak ne demek? Ve bir yapay zekâ neden verisinden daha adil olamaz? Soyut kalmayacağız; gerçek rakamlar ve birkaç satır kodla ilerleyeceğiz.

NEREDE KARŞIMIZA ÇIKIYOR

Yapay zekâyı zaten her gün kullanıyorsunuz

Yapay zekâ, filmlerdeki robot değil. Telefonunuzda, her tıklamanızda karşınızda. Birkaç örnek:

Günlük örnekler

- Instagram ve TikTok'ta çıkan içerikler
- Klavyenin önerdiği bir sonraki kelime
- Netflix ve Spotify önerileri
- Bankanın "şüpheli işlem" uyarısı

Ortak yanları

Hiçbiri düşünmüyor. Her biri milyonlarca geçmiş örneğe bakıp "benzer durumda genelde ne oldu?" sorusunu cevaplıyor. Bugünkü konumuz da bu.

BUGÜNÜN PLANI

Akış

Bölüm	Konu
A	Veri ve "öğrenmek"
B	Bu veri nereden geliyor?
C	Önyargı veriye nasıl girer?
D	Vekil değişken
E	Özet ve tartışma

Bölüm A

Veri ve "Öğrenmek"

Modelin gördüğü dünya, bir tablodan ibaret.

HATIRLATMA

Yapay zekâ örneklerden öğrenir

Bir yapay zekâya kural yazmayız. Ona binlerce örnek gösteririz, o da ortak örüntüyü kendi çıkarır. Bir çocuğa binlerce kedi fotoğrafı gösterip "kedi"yi öğretmek gibi.

Peki bu örnekler nerede duruyor? Bir tablonun içinde. Yapay zekâyı anlamak için önce bu tabloyu anlamak gerekir.

ÖRNEK

Örüntü bulmak neye benzer

E-postaları "spam" ve "normal" diye ayıran filtreyi düşünün. Kimse ona "şu kelimeler spamdır" diye kural yazmadı. Sadece milyonlarca eski e-posta ve her birinin spam olup olmadığı gösterildi.

Filtrenin bulduğu

"Bedava", "kazandınız", "hemen tıkla" gibi kelimeler spam e-postalarda çok, normallerde az geçiyor. Filtre bu istatistiksel örüntüyü yakaladı. Anlamı anladığı için değil, kelime öyle sık tekrar ettiği için.

İşe alım, kredi ve sağlık sistemleri de böyle çalışır. Yalnızca tablonun sütunları değişir.

TABLO

Veri bir tablodur

deneyim	egitim	sehir	işe alındı mı?
5 yıl	Lisans	İzmir	Evet
8 yıl	Y.Lisans	Ankara	Hayır
2 yıl	Lisans	İzmir	Evet

Bir sınıf listesi gibi. Her satır bir kişidir (bir aday). Her sütun, o kişi hakkında bir bilgidir. Yapay zekâ bu tabloya bakıp örüntü arar.

İKİ TÜR SÜTUN

Özellik ve etiket

Özellikler (girdiler)

Modele verdiğimiz bilgiler: deneyim, eğitim, şehir. Model karar verirken bunlara bakar.

Etiket (doğru cevap)

Tahmin etmesini istediğimiz sütun, yani "işe alındı mı?". Geçmişte gerçekte ne olduğunu söyler; model bunu taklit etmeyi öğrenir.

Modelin işi tek cümlede: özelliklere bakıp etiketi tahmin etmeyi öğrenmek.

TANIM

Öğrenmek, örüntü bulmaktır

Yapay zekâ öğrenirken şunu yapar: binlerce satıra bakar ve sorar: "İşe alınanların ortak özellikleri neydi? Alınmayanlardan farkları neydi?" Bulduğu cevabı bir örüntü olarak saklar, yeni bir adayda o örüntüyü uygular.

Yani yapay zekâ bir örüntü bulma makinesidir. Düşünmez, anlamaz, niyet taşımaz; veride tekrar eden kalıpları yakalar. Bu yüzden bir model, verisinden daha akıllı ya da daha adil olamaz. Verisi ne gösteriyorsa onu öğrenir.

SIK KARIŞTIRILAN NOKTA

Model kalabalığı öğrenir, kişiyi değil

Yapay zekâ tek tek satırları ezberlemez. Binlerce örneğin ortalamasından genel bir eğilim çıkarır ve onu daha önce hiç görmediği kişilere uygular. Buna genelleme denir.

Gücü

Yeni bir aday geldiğinde "geçmişte buna benzeyenlere ne olmuş?" diye bakabilir. Hiç görmediği kişiye bile karar verebilir.

Riski

Geçmişteki kalabalık belli bir gruba haksızlık ettiyse, model bu eğilimi de öğrenir ve tek tek masum kişilere uygular.

Bölüm B

Bu Veri Nereden Geliyor?

Modelin öğrendiği geçmiş, kimin geçmişi?

VERİNİN KAYNAĞI

Veri, geçmişin kaydıdır

Bir işe alım yapay zekâsı neyle eğitilir? Geçmişte insanların verdiği işe alım kararlarıyla. Kredi modeli geçmiş kredi kararlarıyla, sağlık modeli geçmiş hasta kayıtlarıyla.

Yani veri, gökten inen tarafsız bir gerçek değildir. Geçmişte olmuş bitmiş şeylerin kaydıdır; iyi yanlarıyla ve haksızlıklarıyla birlikte. Geçmişte bir grup sistematik olarak haksızlığa uğradıysa, bu haksızlık veriye de işlenmiştir.

VERİ NASIL OLUŞUR

Veriyi birileri toplar

Veri kendiliğinden oluşmaz. Formlardan, şirket kayıtlarından, tıklamalardan, sensörlerden toplanır. Ve her toplama adımında bir seçim yapılır.

Sessizce geçen seçimler

Kim dahil edildi, kim dışarıda kaldı? Hangi soru soruldu? "Başarı" nasıl tanımlandı? Bu seçimler veriye, oradan da modele geçer. Kötü ya da eksik veriyle en gelişmiş model bile iyi sonuç veremez. Bu yüzden "hangi model?" sorusundan önce "hangi veri?" diye sorarız.

GERÇEK BİR ÖRNEK

Amazon'un işe alım aracı

Amazon, özgeçmişleri otomatik puanlayan bir işe alım aracı geliştirdi ve onu son on yılın başvurularıyla eğitti. Bu başvuruların büyük çoğunluğu erkeklerden geliyordu.

Sonuç

Model "geçmişte kazananlar erkekti" örüntüsünü öğrendi. Özgeçmişinde "kadın" kelimesi geçen (örneğin "kadın satranç kulübü kaptanı") ya da kadın üniversitelerinden mezun adayları düşük puanladı. Amazon aracı düzeltemedi ve 2017'de kullanımdan kaldırdı.

Kimse "kadınları ele" diye kod yazmadı. Model bunu veriden kendi öğrendi.

Bölüm C

Önyargı Veriye Nasıl Girer?

Üç yol, hepsi günlük hayattan.

1. YOL

Tarihsel önyargı

Geçmiş kararların kendisi adaletsizse, veri bunu taşır. En sık görülen kaynaktır, çünkü kimsenin kötü niyeti yoktur; sistem sadece olanı öğrenir.

Günlük örnek

Bir şirkette geçmişte çoğunlukla erkekler yönetici olduysa, veri "yönetici profili erkektir" der. Model de yeni bir kadın adayı, geçmişe benzemediği için düşük puanlar. Kadının yeteneğiyle ilgisi yoktur, sadece geçmişin tekrarıdır.

2. YOL

Temsil önyargısı

Bazen sorun oranlarda değil, bir grubun veride çok az bulunmasıdır. Model az gördüğü şeyi iyi öğrenemez.

Günlük örnek

Bir yüz tanıma sistemi çoğunlukla açık tenli erkek fotoğraflarıyla eğitildiyse, koyu tenli kadınları çok daha fazla yanlış tanır, çünkü onları yeterince görmemiştir. Sorumuz: bu veri kimi eksik bıraktı?

3. YOL

Ölçüm önyargısı

Bazen "doğru cevap" olarak seçtiğimiz ölçünün kendisi hatalıdır. Yanlış cetvelle ölçersek sonuç da yanlış olur.

Günlük örnek

"İyi çalışan"ı ölçmek için fazla mesai saatini kullanan bir sistem, akşam çocuğuna bakmak için erken çıkan çalışanı (çoğu zaman kadını) otomatik olarak kötü gösterir. Oysa işini çok iyi yapıyor olabilir.

ÖZET

Önyargının üç kaynağı

Kaynak	Kısaca	Sorulacak soru
Tarihsel	Geçmiş kararlar zaten adaletsizdi.	Bu veri kimin geçmişini taşıyor?
Temsil	Bir grup veride çok az var.	Bu veri kimi eksik bıraktı?
Ölçüm	"Başarı"nın tanımı hatalı.	Doğru şeyi mi ölçüyoruz?

Üçünde de sorun modelde değil, ona verdiğimiz veridedir.

Bölüm D

Vekil Değişken

"Cinsiyeti silelim, sorun çözülsün" neden yetmez?

KOD

Kendi verimize bakalım

Elimizde 2000 kişilik bir işe alım verisi var. Genele bakınca dengeli görünüyor, yarısı işe alınmış. Ama cinsiyete göre gruplayınca:

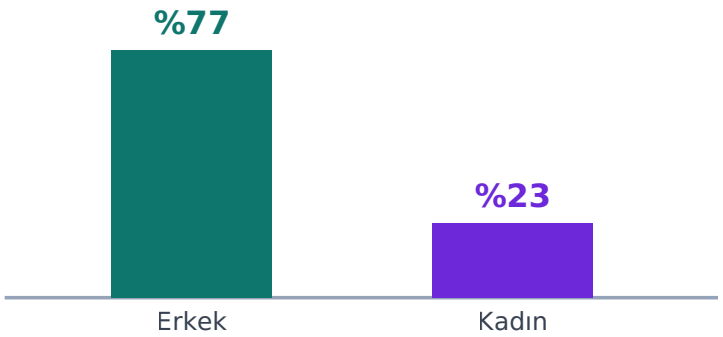
```
print(veri.groupby("cinsiyet")["ise_alindi"].mean())
```

```
erkek 0.77 (%77'si işe alınmış) kadın 0.23 (%23'ü işe alınmış)
```

Bu bir model çıktısı değil, geçmişin gerçek kaydı. Bir modeli bu veriyle eğitirsek aynı farkı öğrenir.

GRAFİK

Geçmişteki fark



Geçmiş verideki işe alınma oranı.

KOD

Cinsiyeti silmek yeter mi?

Akla yatkın bir fikir: model cinsiyeti hiç görmesin, o zaman ayrımcılık yapamaz. Ama verimizde "kariyer boşluğu" (çalışmaya ara verilen yıl) diye bir sütun daha var. Gruba göre bakalım:

```
print(veri.groupby("cinsiyet")["bosluk"].mean())
```

```
erkek 0.54 yıl kadın 1.28 yıl
```

Kadınların ortalama kariyer boşluğu erkeklerin iki katından fazla, büyük ihtimalle doğum ve bakım sorumlulukları yüzünden. Yani boşluğu yüksek olan biri büyük olasılıkla kadındır.

TANIM

Vekil değişken

Vekil değişken (proxy)

Yasak bir bilgiyi (cinsiyet) doğrudan içermez ama onunla o kadar ilişkilidir ki o bilgiyi dolaylı olarak taşır.

Model "yüksek boşluk, düşük şans" kuralını öğrenince, farkında olmadan "kadınları ele" kuralını da öğrenmiş olur. Cinsiyet sütunu hiç olmasa bile.

Başka bir örnek

Bir kredi modelinden ırk bilgisini silseniz bile posta kodu çoğu zaman mahalleyi, mahalle de etnik kökeni ele verir. Vekil değişkenler her yerdedir.

GİZLİ YOL

Silinen cinsiyet, modele başka kapıdan ulaşır



Cinsiyet sütununu silmek kutuyu kaldırır ama gizli yolu kapatmaz.

KONTROL

Önyargı sadece boşlukta değil

"Belki kadınlar yalnızca kariyer boşlukları yüzünden az alınmıştır" diyebiliriz. O zaman aynı boşluk düzeyinde kadın ve erkek eşit mi alınmış, ona bakalım:

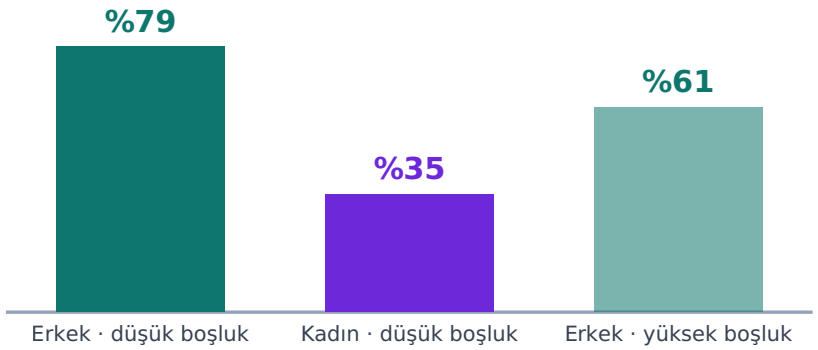
```
Düşük boşluğu olan erkek: %79 işe alınmış Düşük boşluğu olan kadın: %35 işe alınmış Yüksek boşluğu olan erkek: %61 işe alınmış
```

Sonuç

Hiç kariyer boşluğu olmayan bir kadın (%35), kariyer boşluğu olan bir erkekten (%61) bile daha az işe alınmış. Önyargı tek bir sütunda değil, verinin her yerine sinmiş.

GRAFİK

Kadın olmak avantajı siliyor



Ortadaki kadın, kariyer boşluğu olmamasına rağmen en düşük oranda.

ÇIKARIM

Görmezden gelmek, çözmek değildir

Cinsiyeti veriden silmek önyargıyı ortadan kaldırmaz, yalnızca görünmez kılar. Model aynı sonuca vekil değişkenler üzerinden ulaşır.

Bu yüzden bir sistemin "cinsiyeti kullanmıyorum" demesi, "adilim" demesiyle aynı şey değildir. Önyargıyı çözmek için önce onu görmek gerekir, sonraki haftalarda tam olarak bunu yapacağız.

Bölüm E

Özet ve Tartışma

Bugünü toparlayalım.

VERİNİN İKİ YÜZÜ

Aynı veri: hem güç, hem risk

Gücü

Veri sayesinde yapay zekâ, insanın elle bulamayacağı karmaşık örüntüleri yakalar ve büyük ölçekte tutarlı çalışır.

Riski

Aynı veri geçmişin önyargısını da taşır. Model bunu büyük ölçekte tekrar eder ve verisinden daha adil olamaz.

Bir sistemi incelerken ilk soru hep aynı: bu veri kimden geldi, kimi eksik bıraktı, hangi geçmişi taşıyor?

ÖZET

Bugün ne öğrendik?

- Yapay zekânın gördüğü her şey bir tablodur: özellikler ve etiket.
- "Öğrenmek", o tabloda örüntü bulmaktır; düşünmek değil.
- Veri geçmişin kaydıdır. Önyargı ona üç yolla girer: tarihsel, temsil, ölçüm.
- Verimizde geçmiş işe alınma oranı: erkek %77, kadın %23.
- Vekil değişkenler yüzünden cinsiyeti silmek önyargıyı çözmez, gizler.

TARTIŞMA

Birlikte düşünelim

- "Yapay zekâ tarafsızdır çünkü duyguları yoktur" cümlesine bugünden sonra nasıl cevap verirsiniz?
- Hangi verilerde geçmişin önyargısı gizli olabilir (kredi, sınav, sağlık)?
- Her gün kullandığınız hangi uygulamada bir vekil değişken saklı olabilir?
- Bir sistemin "cinsiyeti kullanmıyorum" demesi sizi ikna eder mi?

HAFTA 5 · ÖNİZLEME

Makineler Nasıl Öğrenir? (Sinir Ağları)

Veriyi tanıdık. Gelecek hafta modelin içine giriyoruz: bir yapay zekâ "öğrenmek" derken tam olarak ne yapıyor? Yapay nöron, katmanlar ve öğrenme mekanizmasını adım adım göreceğiz.