YAPAY ZEKÂ VE ADALET EĞİTİMİ · HAFTA 6

Derin Öğrenme ve Büyük Dil Modelleri (ChatGPT)

BAŞLANGIÇ

ChatGPT aslında tek bir şey yapar

Şiir yazmak, kod düzeltmek, soru cevaplamak. Bütün bu yeteneklerin altında tek bir görev var: sıradaki kelimeyi tahmin etmek. Telefon klavyesinin bir sonraki kelimeyi önermesi gibi, ama çok daha güçlü.

Örnek

"Türkiye'nin başkenti ____" cümlesinde model, gördüğü milyarlarca metne dayanarak en olası sonraki kelimenin "Ankara" olduğunu hesaplar. Bir cevap yazarken bunu kelime kelime, defalarca tekrarlar.

ZATEN TANIYORSUNUZ

Büyük bir "sonraki kelime" tahmincisi

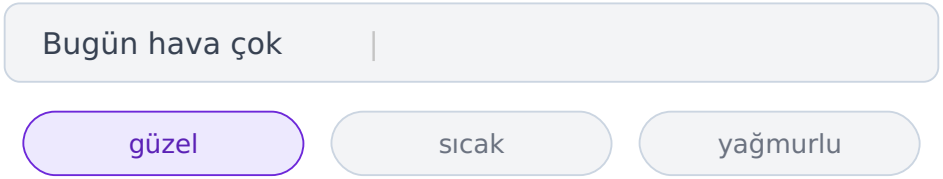

Klavye birkaç kelimeyi ezbere önerir. ChatGPT ise tüm cümlenin bağlamına bakarak her seferinde en olası sonraki parçayı seçer, ve bunu o kadar iyi yapar ki koca paragraflar tutarlı çıkar. Bütün gücü, bu tahminin kalitesinden gelir.

BUGÜNÜN PLANI

Akış

Bölüm	Konu
A	Metni sayıya çevirmek: token ve embedding
B	Dikkat (attention) ve Transformer
C	Dev bir model nasıl eğitilir?
D	Bu neden adalet dersimizin kalbinde?

Bölüm A

Bir Ağ Sadece Sayı Anlar

Ama dil kelimelerden oluşuyor. Bu boşluğu nasıl geçiyoruz?

İLK ENGEL

Sinir ağı "kelime" göremez

Geçen hafta gördük: bir sinir ağı sadece sayılarla çalışır. Çarpar, toplar, aktivasyondan geçirir. Ama "merhaba" bir sayı değil. O halde bir dil modeli metni nasıl işliyor?

İki adımlı çözüm

Önce metni parçalara böleriz (token), sonra her parçayı bir sayı listesine çevririz (embedding). Böylece kelimeler, ağın anlayacağı dile, yani sayılara dönüşür. Sıradaki iki slayt bunu anlatıyor.

1. ADIM

Token: metni parçalara bölmek

Model metni önce küçük parçalara, yani tokenlara ayırır. Bir token bazen bir kelime, bazen bir kelime parçasıdır.

"güçlü" kelimesi "güç" ve "lü" diye iki token olabilir. Model dünyayı bu parçalar üzerinden okur; bir cümle, bir token dizisidir.

2. ADIM

Embedding: kelimeyi anlam koordinatına çevirmek

Her token bir sayı listesine (vektöre) dönüştürülür. Model bu sayıları öyle ayarlar ki anlamca benzer kelimeler birbirine yakın düşer. Buna embedding denir.

Bir anlam haritası gibi

Kelimeleri dev bir harita üzerinde noktalar gibi düşünün. "Kral" ile "kraliçe" yan yana, "Ankara" ile "İstanbul" aynı mahallede, "mutlu" ile "neşeli" komşu olur. Model anlamı bu yakınlık üzerinden yakalar.

GÖRSEL

Kelimelerin anlam haritası

Benzer anlamlar birbirine yakın kümelenir. Model anlamı bu uzayda öğrenir; kelimelerin sözlük tanımını değil, nerede ve nasıl kullanıldıklarını.

Bölüm B

Dikkat ve Transformer

Bugünkü dil modellerini mümkün kılan fikir.

NEDEN BİR FİKİR DAHA GEREK

Kelimeler bağlama göre anlam değiştirir

Token ve embedding tek başına yetmez, çünkü bir kelimenin anlamı etrafındaki kelimelere bağlıdır.

"yüz"

"Denizde yüz" (fiil) mü, "bir yüz gördüm" (surat) mı, "yüz lira" (sayı) mı?

"onu"

"Zeynep kitabı aldı çünkü onu çok sevdi." Buradaki "onu" neye işaret ediyor, kitaba mı, birine mi?

Model doğru anlamı seçmek için cümlenin geri kalanına bakabilmelidir. "Dikkat" bunun için var.

ANAHTAR FİKİR

Dikkat (attention): hangi kelimeye bakmalı?

Model bir kelimeyi işlerken, cümledeki diğer kelimelere ne kadar dikkat edeceğine kendi karar verir. Böylece bağlamı yakalar.

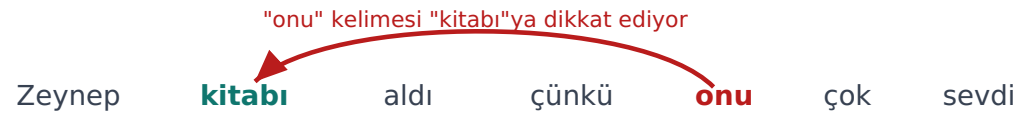

"onu" kelimesi, doğru anlamı bulmak için "kitabı" kelimesine güçlü dikkat verir. Her kelime, her adımda böyle bağ kurar.

MİMARİNİN ADI

Transformer: dikkati ölçekte kullanmak

Bu dikkat fikrini, milyarlarca kelime üzerinde verimli çalışacak şekilde bir araya getiren sinir ağı tasarımına Transformer denir (2017'de tanıtıldı). Bugünkü neredeyse tüm büyük dil modellerinin temeli budur.

Küçük bir ayrıntı

GPT'deki "T" harfi tam olarak Transformer demektir (Generative Pre-trained Transformer). Yani her gün kullandığınız aracın adında, bu haftaki mekanizma gizli.

"BÜYÜK" NE KADAR BÜYÜK

Neden "büyük" dil modeli?

Geçen haftaki örnek ağımızın birkaç yüz düğmesi (parametresi) vardı. Büyük dil modellerinde bu sayı milyarlarca, hatta yüz milyarlarcadır. "Büyük" bunu kasteder.

Ölçek neden önemli?

Model büyüdükçe ve daha çok metin gördükçe dildeki incelikleri (dilbilgisi, üslup, olgular, hatta mantık kırıntıları) yakalayabiliyor. Zekâ gibi görünen şey, büyük ölçüde bu ölçeğin sonucudur.

Bölüm C

Dev Bir Model Nasıl Eğitilir?

Aynı öğrenme döngüsü, çok büyük bir ölçekte.

1. AŞAMA

Ön-eğitim: interneti okuyarak dili öğrenmek

Modele internetten devasa miktarda metin verilir (kitaplar, makaleler, web siteleri) ve tek bir oyun oynatılır: sıradaki kelimeyi tahmin et. Doğru tahmin edene kadar, geçen haftaki döngüyle (kayıp, gradyan inişi, geri yayılım) düğmeleri ayarlanır.

Ön-eğitim (pre-training)

Bu oyun trilyonlarca kez oynanır. Model bu sırada dilbilgisini, olguları ve üslupları kendi kendine öğrenir. Bu aşama çok pahalıdır: dev bilgisayarlar, haftalar ya da aylar.

2. AŞAMA

İnce ayar ve insan geri bildirimi (RLHF)

Ön-eğitimden çıkan ham model dili bilir ama kaba olabilir; işe yaramaz, kayıtsız, hatta zararlı cevaplar verebilir. İkinci aşamada onu yardımcı ve güvenli olacak şekilde ayarlarız.

İnsan geri bildirimiyle pekiştirme (RLHF)

İnsanlar modelin farklı cevaplarını "bu daha iyi, bu daha kötü" diye puanlar. Model bu puanlara göre ayarlanır, iyi bulunan cevaplara yönelir. ChatGPT'nin kibar ve yardımsever tavrı, doğrudan insan tercihlerinden öğrenilmiştir.

BAŞTAN SONA

Bir asistanın oluşumu

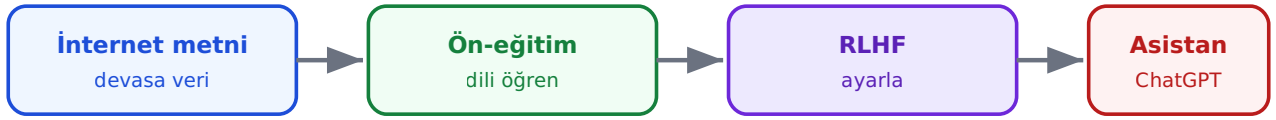

Tanıdık bir akış: veri, eğitim, insan ayarı, ürün. Sadece ölçek ve bir ayar adımı eklendi.

Bölüm D

Bu Neden Adalet Dersimizin Kalbinde?

Dev bir model de, sonuçta, verisinin yansımasıdır.

TANIDIK NOKTA

Bir dil modelinin verisi neredeyse tüm internet

Hafta 4'ün fikri burada da geçerli, hatta daha güçlü: bir dil modeli verisinin yansımasıdır. Ve onun verisi neredeyse tüm internettir; insanlığın en iyi bilgisiyle birlikte tüm önyargıları, klişeleri ve hataları.

Sonuç

İnternette "doktor" çoğunlukla erkekle, "hemşire" kadınla anılıyorsa, model bu kalıbı öğrenir ve üretir. Kimse ona öğretmese bile, çünkü verisinde bu kalıp var.

YENİ GÜÇ, YENİ RİSKLER

Dil modellerine özgü üç risk

Önyargı ve klişe

Cinsiyet, ırk ve meslek klişelerini metinlere sinsi biçimde taşıyabilir, büyük ölçekte pekiştirebilir.

Halüsinasyon (uydurma)

Model sıradaki kelimeyi tahmin ettiği için, bilmediği bir şeyde kendinden emin ama yanlış cevaplar uydurabilir. Doğruluk garantisi yoktur.

Dil ve kültür yanlılığı

Verisi çoğunlukla İngilizce ve Batı kaynaklı olduğundan, başka dilleri ve kültürleri (örneğin Türkçe bağlamları) daha zayıf ya da yanlı temsil edebilir.

İYİ HABER

Aynı denetçi soruları burada da geçerli

Dil modelleri çok daha büyük ve karmaşık, ama sorduğumuz sorular değişmiyor. Kursun geri kalanında öğreneceğiniz denetim araçları ChatGPT gibi modeller için de geçerlidir.

Sorular yine aynı

Bu model hangi veriden öğrendi, kimi eksik bıraktı (H4)? Bir cevabı neden verdi, açıklanabilir mi (H7)? Farklı gruplar için adil mi, nasıl ölçeriz (H8)? Önyargısı nasıl azaltılır (H9)?

SÖZLÜK

Dil modeli terimleri

Terim	Kısaca
Dil modeli	Sıradaki kelimeyi tahmin etmeyi öğrenen model.
Token	Metnin bölündüğü küçük parça (kelime ya da parçası).
Embedding	Bir token'ın anlamını taşıyan sayı vektörü; benzerler yakın durur.
Dikkat (attention)	Her kelimenin hangi kelimelere bakacağına karar vermesi.
Transformer	Dikkati ölçekte kullanan mimari; dil modellerinin temeli.
Ön-eğitim	Devasa metinle "sonraki kelime" oyununu oynayarak dili öğrenme.
RLHF	İnsan geri bildirimiyle modeli yardımcı ve güvenli hale getirme.
Halüsinasyon	Modelin kendinden emin ama yanlış cevap vermesi.

ÖZET

Bugün ne öğrendik?

- ChatGPT tek bir şey yapar: bağlama bakıp sıradaki kelimeyi tahmin eder.
- Metin önce tokenlara bölünür, sonra embedding ile anlam taşıyan sayılara çevrilir.
- Dikkat (attention) bağlamı yakalar; bunu ölçekte kullanan mimari Transformer'dır.
- Eğitim iki aşama: devasa metinle ön-eğitim, sonra insan geri bildirimiyle RLHF.
- Devasa da olsa model verisinin yansımasıdır; internetin önyargılarını taşır ve uydurma yapabilir.
- Denetçinin soruları bu modeller için de aynen geçerli.

TARTIŞMA

Birlikte düşünelim

- ChatGPT'nin "sadece sıradaki kelimeyi tahmin etmesi" sizce onu daha az mı etkileyici yapıyor, yoksa daha mı çok?
- Bir modelin kendinden emin ama yanlış olabilmesi, onu günlük hayatta kullanırken ne yapmanız gerektiğini söyler?
- Türkçe içerikte bir dil modelinin hangi önyargıları ya da eksiklikleri olabilir? Denediniz mi?

HAFTA 7 · ÖNİZLEME

Modelin İçini Açmak: "Neden Bu Kararı Verdin?"