YAPAY ZEKÂ VE ADALET EĞİTİMİ · HAFTA 7

Modelin İçini Açmak: "Neden Bu Kararı Verdin?"

BUGÜNÜN BÜYÜK SORUSU

"Neden?" diye sorabilir miyiz?

Diyelim bir kadın aday reddedildi. En doğal soru şudur: **"Neden? Ne yapsaydım kabul edilirdim?"** Modelden bu cevabı alabilir miyiz?

Bugünün amacı

Modelin kararının **gerekçesini** insanın anlayacağı dile çevirmek. Buna **"açıklanabilir yapay zekâ"** denir — ve bir sistemi sorgulamanın en güçlü aracıdır.

Bu, eğitimin başından beri konuştuğumuz "yapay zekâyı denetlemek" fikrinin kalbidir.

BUGÜNÜN PLANI

Akış

Bölüm	Konu
A	Kara kutu problemi: neden açıklama şart?
B	Model genelde neye bakıyor? (küresel açıklama)
C	Katsayılar: "ne kadar" değil, "ne yönde"
D	Bu kişi neden reddedildi? (yerel açıklama)
E	Açıklama, bir denetim aracıdır

Bölüm A

Kara Kutu Problemi

Cevabı görüyoruz ama gerekçesini göremiyoruz.

TEMEL SORUN

"Kara kutu" ne demek?



Girdiyi ve çıktıyı görürüz ama arada ne olduğunu göremeyiz. Model "RED" der — **ama neden dediğini söylemez.** İşte kara kutu problemi budur.

NEDEN UMURSAYALIM?

Açıklama bir lüks değil, bir haktır

Kararı anlamak sadece meraktan değil; çok somut nedenlerle gereklidir:

Birey için

- **İtiraz hakkı:** "Neden reddedildim?" sorusuna cevap
- **Düzeltme:** "Ne yapsam kabul edilirdim?"

Toplum için

- **Güven:** körü körüne değil, gerekçesiyle güvenmek
- **Denetim:** ayrımcılığı yakalamak ve yasal hesap sormak

Açıklayamadığımız bir sistemi ne düzeltebilir ne de ona güvenebiliriz.

BUGÜNÜN ANAHTAR KAVRAMI

Açıklanabilir Yapay Zekâ (XAI)

Tanım

Bir modelin kararını, **insanın anlayacağı bir gerekçeye** çeviren yöntemlerin tümü. "Model bu kararı şu yüzden verdi" diyebilmek.

İki temel soru sorarız — ve bugün ikisini de yanıtlayacağız:

Küresel açıklama

"Model **genel olarak** neye önem veriyor?" — Sistemin geneli hakkında.

Yerel açıklama

"Model **bu kişi** için neden böyle karar verdi?" — Tek bir karar hakkında.

Bölüm B

Model Genelde Neye Bakıyor?

Küresel açıklama: sistemin en önemli düğmelerini bulmak.

BASİT AMA DÂHİCE BİR FİKİR

Bir özelliği "bozarsak" ne olur?

Bir özelliğin ne kadar önemli olduğunu anlamanın kolay bir yolu var: o sütunu **rastgele karıştır** (bilgiyi boz) ve modelin doğruluğu ne kadar düşüyor bak.

Mantık

Karıştırınca doğruluk **çok düşüyorsa**, model o özelliğe çok güveniyordu → çok önemli. **Az düşüyorsa**, o özellik zaten pek işine yaramıyordu → önemsiz. Buna **"permütasyon önemi"** denir.

Bir takımdan bir oyuncuyu çıkarıp takımın ne kadar kötüleştiğine bakmak gibi.

GÖRELİM

Hangi özellik ne kadar önemli?

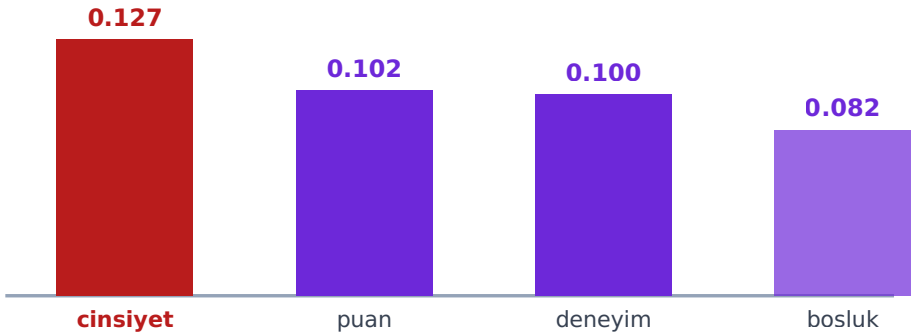
```
importance = permutation_importance(model, X_test, y_test)
```

```
Özellik Önem (doğruluk düşüşü) cinsiyet 0.127 ← en yüksek puan 0.102 deneyim 0.100 bosluk 0.082
```

Model kararlarını en çok **cinsiyete** dayandırıyor — deneyim ve puandan bile fazla. Bu tek satır, sistemin kalbindeki sorunu ortaya döküyor.

GÖRSELLEŞTİR

En önemli özellik: cinsiyet



Bir işe alım modelinin en çok cinsiyete bakması, tek başına büyük bir **kırmızı bayraktır.**

Bölüm C

Sadece "Ne Kadar" Değil, "Ne Yönde"

Önem bize büyüklüğü söyler; katsayı yönü de söyler.

BİR ADIM DAHA

Katsayılar: artı mı, eksi mi?

Permütasyon önemi "cinsiyet önemli" der ama *hangi yönde* demez. Modelin katsayılarına (düğme değerlerine) bakınca yönü de görürüz:

```
cinsiyet -2.73 kadın olmak → şansı büyük ölçüde DÜŞÜRÜR bosluk -2.24 boşluk arttıkça → şans DÜŞER deneyim
+0.52 deneyim arttıkça → şans ARTAR puan +0.10 puan arttıkça → şans biraz ARTAR
```

Eksi işaret "aleyhte", **artı** işaret "lehte" demek. Büyüklük ise etkinin gücünü verir. Cinsiyet ve boşluğun ne kadar güçlü **negatif** olduğuna dikkat.

ÖNEMLİ BİR UYARI

Her model bu kadar okunaklı değil

Bizimki basit bir model olduğu için düğmelerini doğrudan okuyabildik. Ama yapay zekânın çoğu böyle şeffaf değildir.

Basit modeller

Katsayıları okunabilir; kararı doğrudan gerekçelendirmek kolay. "Cam kutu" gibi.

Derin ağlar (ör. ChatGPT)

Milyonlarca düğme; kimse tek tek okuyamaz. İşte o zaman XAI yöntemleri **zorunlu** hale gelir — kutuyu dışarıdan sorgulamak gerekir.

Bölüm D

Bu Kişi Neden Reddedildi?

Yerel açıklama: tek bir kararı mercek altına almak.

SOMUT BİR ADAY

Zeynep'in başvurusu

deneyim	kariyer boşluğu	sınav puanı	cinsiyet	model kararı
5,4 yıl	0,76 yıl (düşük)	69 (iyi)	kadın	%39 → RED

Zeynep gayet nitelikli: makul deneyim, **düşük** kariyer boşluğu, iyi bir sınav puanı. Yine de model onu reddetti (işe alınma olasılığı yalnızca %39). **Neden?** Hadi modeli konuşturalım.

EN SEZGİSEL AÇIKLAMA YÖNTEMİ

"Ya şu değişseydi?" — karşı-olgusal

Karşı-olgusal açıklama

Kişinin **tek bir özelliğini** değiştirip modeli tekrar çalıştırırız ve kararın değişip değişmediğine bakarız. "Şu farklı olsaydı, sonuç ne olurdu?"

Bu, "ne yapsaydım kabul edilirdim?" sorusunun tam da cevabıdır — ve bir kararın gerçekte neye dayandığını ifşa etmenin en dürüst yoludur. Zeynep için tek tek deneyelim.

TEK TEK DEĞİŞTİRELİM

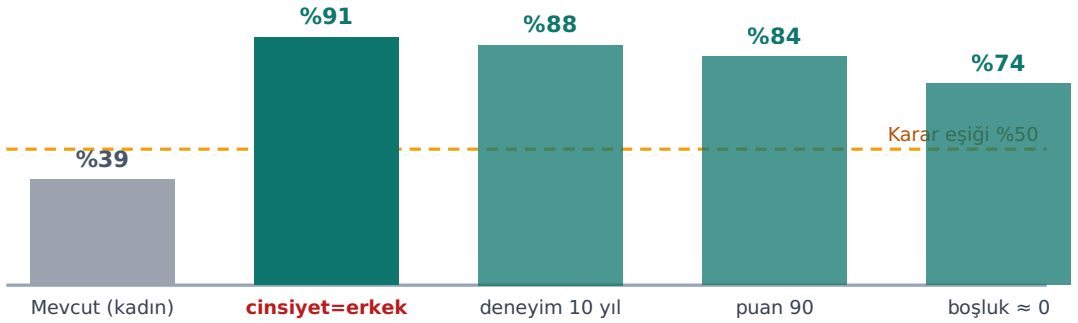
Zeynep için "ya şöyle olsaydı?"

```
Zeynep (mevcut hâli): %39 → RED SADECE cinsiyet "erkek" olsaydı: %91 → KABUL SADECE deneyim 10 yıl
olsaydı: %88 → KABUL SADECE puan 90 olsaydı: %84 → KABUL SADECE boşluk sıfıra inseydi: %74 → KABUL
```

Her satırda **yalnızca bir şey** değişti, kalan her şey aynı kaldı. Hepsi kararı çevirebiliyor — ama en büyük sıçrama hangisinde?

EN ÇARPICI GRAFİK

Zeynep'i asıl eleyen: cinsiyeti



Sadece cinsiyeti değiştirmek %39'u %91'e fırlatıyor — en büyük sıçrama. Zeynep'in niteliği değil, kadın olması belirleyici.

Açıklama neyi ifşa etti?

Zeynep'in reddedilmesinin en büyük tek nedeni **niteliksizliği değil, cinsiyetiydi.**

Model bunu bize asla "söylemezdi" — **ama sorunca gösterdi.**

Bölüm E

Açıklama, Bir Denetim Aracıdır

Bu eğitimin kalbine geldik: yapay zekâyı sorgulamak.

NEDEN BU ÖNEMLİ?

Açıklama = önyargıyı yakalama feneri

Bugün üç güçlü araç öğrendik ve üçü de aynı işe yarıyor: karanlıkta kalan önyargıyı görünür kılmak.

Elimizdeki fener

- **Küresel önem:** "Model genelde neye bakıyor?" → cinsiyet en tepede
- **Katsayı yönü:** "Lehte mi aleyhte mi?" → cinsiyet güçlü aleyhte
- **Karşı-olgusal:** "Bu kişi neden?" → Zeynep'i cinsiyeti eledi

Ölçemediğimiz ve açıklayamadığımız şeyi düzeltemeyiz. Açıklama, düzeltmenin ilk adımıdır.

DÜRÜST OLALIM

Açıklama sihirli değnek değil

Ne yapar

Kararın neye dayandığını gösterir; önyargıyı yakalamamıza, itiraz ve düzeltme için kanıt üretmemize yarar.

Ne yapmaz

Kararı **haklı çıkarmaz.** "Cinsiyete baktı" açıklaması, bunun doğru olduğu anlamına gelmez — tam tersine, bir uyarıdır. Ayrıca kötü tasarlanmış açıklamalar yanıltıcı da olabilir.

Açıklama bir **başlangıçtır**: sorunu görünür kılar, çözmek yine bizim işimizdir.

ÜÇ HAFTANIN BİRLEŞİMİ

Yapay zekâyı denetleme döngüsü



Denetim, döngüyü kapatır: açıklamayla bulduğumuz önyargıyı geri besleyip sistemi düzeltiriz.

TOPARLAYALIM

Bugün ne öğrendik?

- Model bir **kara kutudur**: cevabı verir, gerekçesini kendiliğinden söylemez.
- Kararı anlamak bir **haktır**: itiraz, düzeltme, güven ve denetim için şart.
- **Küresel açıklama** (permütasyon önemi): modelimizin en çok baktığı özellik **cinsiyet** (0.127).
- **Katsayılar** yönü verir: cinsiyet ve boşluk güçlü **aleyhte** (−).
- **Karşı-olgusal** (yerel açıklama): Zeynep'i cinsiyeti eledi (%39 → erkek olsa %91).
- Açıklama, önyargıyı görünür kılan **denetim feneridir** — ama kararı haklı çıkarmaz.

SÖZ SİZDE

Tartışma

Birlikte düşünelim

- Sizce bir şirket, reddettiği her adaya "neden" açıklaması vermek zorunda olmalı mı?
- Zeynep bu karşı-olgusal sonucu görse ne yapabilirdi? Bu bir kanıt sayılır mı?
- Çok güçlü ama hiç açıklanamayan bir modelle, biraz daha zayıf ama tamamen açıklanabilir bir model arasında hangisini seçerdiniz? Nerede?

HAFTA 8 · ÖNİZLEME

Adaleti Ölçmek: "Adil" Tam Olarak Ne Demek?

Önyargıyı gördük, kanıtladık ve açıkladık. Peki "adil bir yapay zekâ" nedir? Herkese aynı oranı vermek mi, eşit fırsat mı, yoksa başka bir şey mi? Gelecek hafta adaletin farklı — ve bazen birbiriyle çelişen — tanımlarını öğrenip bir sistemi resmî olarak nasıl denetleyeceğimizi konuşacağız.