YAPAY ZEKÂ VE ADALET EĞİTİMİ · HAFTA 8

Adaleti Ölçmek: "Adil" Tam Olarak Ne Demek?

BUGÜNÜN BÜYÜK SORUSU

"Adil" tek bir şey mi?

"Adalet" hepimizin kullandığı bir kelime — ama herkesin aklında farklı bir şey var. Bir işe alım sistemi için "adil" ne demek olmalı?

Üç makul ama farklı cevap

- "Her gruptan **aynı oranda** insan alınmalı."
- "**Nitelikli** herkes, grubu ne olursa olsun, eşit şans almalı."
- "Sistemin verdiği 'evet', her grup için **aynı derecede güvenilir** olmalı."

Üçü de kulağa adil geliyor. Bugün göreceğiz: hepsini aynı anda sağlamak çoğu zaman **imkânsız.**

BUGÜNÜN PLANI

Akış

Bölüm	Konu
A	"Adalet" neden belirsiz bir kelime?
B	Üç adalet tanımı ve bunları nasıl ölçeriz
C	İmkânsızlık: hepsini birden sağlayamazsın
D	Öyleyse ne yapmalı? Adalet bir seçimdir
E	Denetçinin çıktısı: adalet raporu

Bölüm A

"Adalet" Belirsiz Bir Kelimedir

Aynı olaya bakan iki kişi, iki farklı "adil" görebilir.

BİR DÜŞÜNCE DENEYİ

İki müdür, iki "adalet"

Müdür Ayşe

"Adalet, sonuçta eşitliktir. İşe aldığımız kişilerin **yarısı kadın, yarısı erkek** olmalı — toplumu yansıtsın."

Müdür Can

"Adalet, süreçte eşitliktir. Herkese **aynı ölçütü** uygularım; kim daha nitelikliyse o alınır, oran ne çıkarsa çıksın."

İkisi de samimi, ikisi de "adaleti" savunuyor — ama **zıt şeyler** istiyorlar. İşte bu yüzden adaleti önce **tanımlamak**, sonra ölçmek gerekir.

BUGÜNKÜ ÇERÇEVE

Üç farklı adalet sorusu

Adaletin onlarca teknik tanımı var; biz en yaygın üçünü, sade isimlerle öğreneceğiz. Her biri farklı bir soruya "evet" arar:

1 · Demografik eşitlik

"Her gruptan aynı oranda mı seçiyoruz?"

2 · Fırsat eşitliği

"Nitelikli kişiler, grubu ne olursa olsun eşit mi seçiliyor?"

3 · Öngörü eşitliği

"Sistemin 'evet'i, her grup için aynı derecede güvenilir mi?"

Bölüm B

Üç Tanım — ve Modelimizde Ölçümü

Her tanımı önce anlayıp sonra kendi modelimize uygulayacağız.

1 · EN BİLİNEN TANIM

Demografik eşitlik

Tanım

Seçilme oranı her grupta **aynı** olmalı. Model kadınların da erkeklerin de aynı yüzdesine "işe al" demeli.

Bu, hukukta çok kullanılan bir ölçüttür. ABD'deki ünlü **"beşte dört (4/5) kuralı"** der ki: bir grubun seçim oranı, en yüksek grubun **%80'inin altına** düşerse, bu ayrımcılık işaretidir (hukukta "disparate impact").

Şimdi modelimizi bu kurala göre ölçelim.

ÖLÇÜM

Modelimiz sınıfta kaldı

```
Seçim oranı: erkek %83 · kadın %22 Oran (kadın ÷ erkek) = 22 / 83 = 0.26
```

4/5 kuralı

Sınır 0.80'di. Bizim oranımız **0.26** — kuralın çok altında. Hukuki dilde bu, açık bir **ayrımcı etki** göstergesidir. Model demografik eşitlik testinden kaldı.

2 · "AMA NİTELİK FARKLIYSA?" İTİRAZI

Fırsat eşitliği

Müdür Can itiraz edebilir: "Belki de gerçekten daha az nitelikli kadın vardı; oranların farklı olması normal." Peki bunu nasıl kontrol ederiz?

Tanım

Sadece **gerçekten nitelikli** (işe alınmayı hak eden) kişilere bakarız. Bu kişiler arasında seçilme oranı gruplar arasında eşit mi? Buna teknik dilde "gerçek pozitif oranı (TPR)" denir.

Yani: "Hak eden bir kadın ile hak eden bir erkek, eşit şans alıyor mu?"

ÖLÇÜM

Nitelikli kadınlar bile geride

```
Nitelikliler içinde seçilme oranı (fırsat): erkek %94 · kadın %73
```

İtiraz çürüdü. **Aynı derecede nitelikli** olsalar bile, kadınların yalnızca %73'ü seçilirken erkeklerin %94'ü seçiliyor. Nitelik farkı değil bu — **fırsat farkı.**

Sonuç

Model fırsat eşitliği testinden de kaldı. Hak eden bir kadın, hak eden bir erkekten sistematik olarak daha az şans alıyor.

3 · FARKLI BİR AÇI

Öngörü eşitliği

Tanım

Modelin verdiği "evet" kararı, her grup için **aynı derecede güvenilir** olmalı. Yani "işe al" dediklerinin ne kadarı gerçekten doğru çıkıyor? (Teknik adı: "kesinlik / PPV".)

Bu tanım kararı alan işveren için önemlidir: "Bu sistemin 'evet'ine kadınlar için de erkekler için de aynı ölçüde güvenebilir miyim?"

ÖLÇÜM

Üçüncü tanımda da eşitsizlik

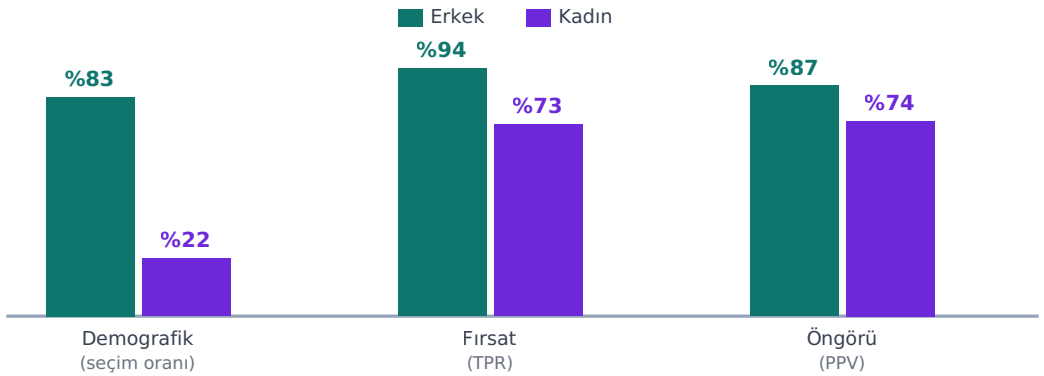
```
"Evet" denenlerin gerçekten doğru olma oranı (öngörü): erkek %87 · kadın %74
```

Model "işe al" dediğinde, bir erkek için %87 haklı çıkıyor, bir kadın için yalnızca %74. Yani sistemin kararı kadınlar için biraz daha **güvenilmez.**

Üç farklı tanım, üç farklı açı — ama hepsinde aynı yön: kadınların aleyhine.

ÜÇ TANIM YAN YANA

Hangi mercekten baksak, uçurum var



Üç tanımda da erkekler önde. Ama uçurumun büyüklüğü tanıma göre değişiyor — işte bu ayrıntı çok önemli.

Bölüm C

İmkânsızlık: Hepsini Birden Sağlayamazsın

Bu haftanın en şaşırtıcı ve en önemli gerçeği.

KRİTİK BİR GERÇEK

Grupların "taban oranı" farklı

Verimizdeki en can alıcı nokta şu: gerçek etikette (geçmiş kararlarda) nitelikli sayılanların oranı gruplar arasında zaten farklı:

```
Geçmiş veride "alınmayı hak etmiş" sayılanlar: erkek %77 · kadın %22
```

Bu farka matematik "**taban oran farkı**" der. Ve tam da bu fark yüzünden, birazdan göreceğimiz şaşırtıcı sonuç ortaya çıkıyor.

BİR DENEY YAPALIM

Ya demografik eşitliği zorlarsak?

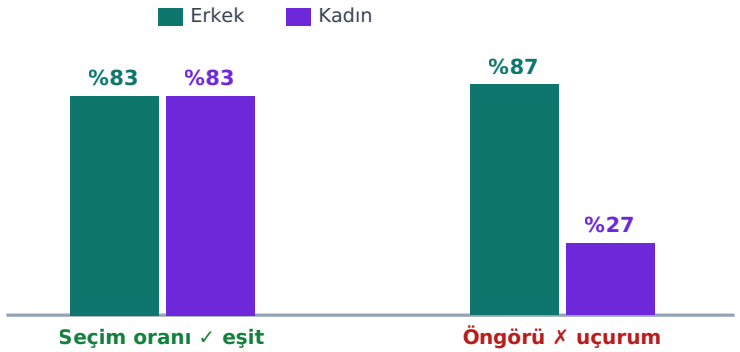
"Tamam" diyelim, "seçim oranlarını eşitleyelim, iş bitsin." Kadınlar için eşiği düşürüp erkeklerle aynı oranda (%83) kadın alalım. Adil, değil mi? Sonuca bakalım:

```
Demografik eşitlik ZORLANDI → seçim: erkek %83, kadın %83 ✓ Ama şimdi öngörü doğruluğu (PPV): erkek %87 · kadın %27 Genel doğruluk: %86 → %62
```

Bir tanımı düzelttik, ama **başka iki şey birden bozuldu.**

BİRİNİ KAZAN, ÖTEKİNİ KAYBET

Battaniye kısa: birini örtsen öteki açık kalıyor



Seçim oranını eşitledik (solda) ama modelin kadınlar için "evet"i artık çok daha güvenilmez (sağda). Adalet tanımları bir battaniye gibi.

İmkânsızlık teoremi

Grupların taban oranları farklı olduğunda, bu adalet tanımlarını **aynı anda** sağlamak **matematiksel olarak imkânsızdır.**
Birini seçmek zorundasın — ve seçtiğin, kaçınılmaz olarak diğerinden ödün verir.

Bu bir mühendislik eksikliği değil; matematiğin bir sınırıdır (Kleinberg ve ark., 2016).

DÜRÜST BİR HATIRLATMA

Peki taban oranın kendisi adil mi?

Burada Hafta 4'e dönmeliyiz. "Erkek %77, kadın %22 nitelikli" diyen etiketler nereden geldi? **Önyargılı geçmişten.** Yani ölçtüğümüz her metrik, aslında **bozuk bir cetvele** göre ölçülüyor.

Derin nokta

Matematik bize "hangi tanımı seçersen bir bedeli var" der ama "hangi geçmiş doğruydu" diyemez. Bu yüzden adalet asla yalnızca bir hesap değildir — **bir değer yargısıdır.**

Bölüm D

Öyleyse Ne Yapmalı?

Adalet, hesaplanan değil, seçilen bir şeydir.

RAHATSIZ EDİCİ AMA GERÇEK

"Tek doğru tanım" yoktur

Hangi adalet tanımının "doğru" olduğu, matematiğe değil **bağlama ve değerlere** bağlıdır. Doğru soru "hangisi matematiksel olarak doğru?" değil, şudur:

Sorulacak sorular

- Bu kararda **kim, ne tür bir hatadan** zarar görür?
- Yanlış "red" mi daha kötü, yanlış "kabul" mü? (İşe alım? Kanser taraması? Kredi?)
- Tarihsel bir haksızlığı **telafi mi** etmeliyiz, yoksa yalnızca tekrar etmemeye mi çalışmalıyız?

KİM KARAR VERMELİ?

Bu, tek başına mühendisin kararı değil

Yanlış yol

Bir mühendisin sessizce "ben demografik eşitlik seçtim" deyip kodu yazması. Bu, gizli bir değer yargısını teknik bir karar gibi göstermektir.

Doğru yol

Tanımı **açıkça** masaya koymak; etkilenenlerle, hukukçularla, yöneticilerle birlikte, bilinçli ve kayıt altında seçmek. Karar şeffaf olmalı.

Denetçinin görevi doğru cevabı dayatmak değil, **seçimi ve bedelini görünür kılmaktır.**

Bölüm E

Denetçinin Çıktısı: Adalet Raporu

Öğrendiğimiz her şeyi tek bir belgede birleştirelim.

SOMUT ÇIKTI

Bir adalet denetimi neleri içerir?

Adım	Soru	Bu eğitimde
1. Veri	Veri kimden geldi, kimi eksik bıraktı?	H4
2. Model	Model önyargıyı tekrar ediyor mu?	H5
3. Açıklama	Kararlar neye dayanıyor?	H7
4. Metrikler	Hangi adalet tanımı, ne kadar ihlal ediliyor?	H8
5. Karar	Hangi tanımı, neden seçtik? Bedeli ne?	H8

İşte bu tablo, sizin üreteceğiniz denetim raporunun iskeletidir.

TOPARLAYALIM

Bugün ne öğrendik?

- "Adalet" tek bir şey değildir; en az üç makul ama farklı tanımı vardır.
- **Demografik eşitlik** (seçim %83/%22, oran 0.26 → 4/5 kuralını kırıyor).
- **Fırsat eşitliği** (nitelikliler: %94/%73) — kadınlar hak etseler bile geride.
- **Öngörü eşitliği** (güvenilirlik: %87/%74).
- **İmkânsızlık:** taban oranlar farkıysa hepsini birden sağlayamazsın; birini seçince (%83/%83) öngörü çöküyor (%87/%27).
- Adalet bir hesap değil, **bilinçli ve şeffaf bir seçimdir.**

SÖZ SİZDE

Tartışma

Birlikte düşünelim

- Bir işe alım sistemi için siz hangi adalet tanımını seçerdiniz? Ya bir **kanser taraması** için? Değişir mi?
- "Geçmişteki haksızlığı telafi etmek için kadınlara pozitif ayrımcılık yapılmalı" fikrine ne dersiniz — bu adil mi, adaletsiz mi?
- İmkânsızlık teoremi sizi umutsuzluğa mı düşürdü, yoksa "seçim bizim" olması güç mü verdi?

HAFTA 9 · ÖNİZLEME

Önyargıyı Azaltmak: Çözüm Yolları

Artık önyargıyı görebiliyor, kanıtlayabiliyor, açıklayabiliyor ve ölçebiliyoruz. Peki onu **azaltmak** için ne yapabiliriz? Gelecek hafta veriyi düzeltmekten, modeli eğitirken adalet kısıtı koymaya ve kararı sonradan dengelemeye kadar somut çözüm yollarını — ve her birinin bedelini — konuşacağız.