YAPAY ZEKÂ VE ADALET EĞİTİMİ · HAFTA 9

Önyargıyı Azaltmak: Çözüm Yolları

BUGÜNÜN BÜYÜK FİKRİ

Önyargı azaltılabilir — bedava değil

İyi haber

Önyargı kaderimiz değil. Verinin, eğitimin veya kararın farklı noktalarına müdahale ederek uçurumu ciddi biçimde **daraltabiliriz.** Bugün üç yöntemi gerçekten uygulayacağız.

Dürüst haber

Genellikle bir **denge** vardır: adaleti artırdıkça, modelin ham "doğruluğu" bir miktar düşer. "Bedava öğle yemeği yoktur." Asıl beceri, bu dengeyi bilinçli kurmaktır.

BUGÜNÜN PLANI

Akış

Bölüm	Konu
A	Nereye müdahale edebiliriz? Üç nokta
B	Üç yöntem ve her birini modelimizde ölçmek
C	Adalet ve doğruluk dengesi
D	Asıl çözüm, bir metrik oyunundan fazlasıdır
E	Tüm yolculuğu birleştirmek

Bölüm A

Nereye Müdahale Edebiliriz?

Boru hattının üç farklı noktasına dokunabiliriz.

ÜÇ MÜDAHALE NOKTASI

Önyargıyı üç yerde yakalayabiliriz



Aynı boru hattı, üç farklı fırsat. Her müdahalenin kendine göre gücü ve bedeli var.

ÜÇ AİLE, TEK BAKIŞTA

Yöntemleri tanıyalım

1 · Ön-işleme — "veriyi düzelt"

Model görmeden önce veriyi daha dengeli hale getir. Aynayı temizle.

2 · İç-işleme — "eğitirken kural koy"

Modele öğrenirken "sadece doğru değil, adil de ol" diye bir kısıt ekle.

3 · Son-işleme — "kararı sonradan dengele"

Eğitilmiş modelin kararlarını, gruplar arası dengeyi sağlayacak şekilde ayarla.

Bölüm B

Üç Yöntem — ve Modelimizde Ölçüm

Başlangıç noktamız: erkek %83, kadın %22, doğruluk %86.

1 · ÖN-İŞLEME

Veriyi düzeltmek

Sorun aynadaysa, aynayı temizleyelim. Model eğitilmeden önce veriye müdahale ederiz. Birkaç yolu var:

Yeniden ağırlıklandırma

Az temsil edilen grubun örneklerine eğitimde daha fazla "ağırlık" ver — model onları daha ciddiye alsın.

Diğer yollar

Grupları dengeleyecek şekilde örnek çoğalt/azalt; vekil değişkenleri (posta kodu gibi) tespit edip temizle.

Biz "yeniden ağırlıklandırma"yı uygulayacağız.

ÖLÇÜM · ÖN-İŞLEME

Uçurum yarı yarıya indi

```
Öncesi: erkek %83 · kadın %22 (fark 0.61) · doğruluk %86 Sonrası: erkek %67 · kadın %34 (fark 0.33) · doğruluk %82
```

Sadece veriyi dengeleyerek uçurumu neredeyse **yarıya** düşürdük ve doğruluktan çok az (%86→%82) ödün verdik. En hafif dokunuşla ciddi bir iyileşme.

Artısı

Basit, modelden bağımsız, sonraki her şeyi iyileştirir. Çoğu zaman ilk denenecek yöntem.

2 · İÇ-İŞLEME

Eğitirken adalet kısıtı koymak

Bu sefer veriye değil, **öğrenme sürecine** müdahale ediyoruz. Modele iki hedef veriyoruz: "hem doğru tahmin et, **hem de gruplar arası farkı küçük tut.**"

Nasıl çalışır?

Hatırlayın (H5): model "hatayı azaltacak" şekilde düğmelerini ayarlıyordu. Şimdi "hata"nın tanımına **adaletsizliği de** ekliyoruz. Model artık ayrımcılık yaptığında da "ceza" alıyor, o yüzden ondan kaçınmayı öğreniyor.

ÖLÇÜM · İÇ-İŞLEME

Uçurum neredeyse kapandı

```
İç-işleme (adalet kısıtı): erkek %50 · kadın %49 (fark 0.01) · doğruluk %70
```

Seçim oranları neredeyse eşitlendi — fark %61'den %1'e düştü. Ama doğruluk bedeli daha büyük: %86'dan **%70**'e indi.

Denge burada görünür oluyor

Daha çok adalet istedik, daha çok "doğruluk" ödedik. Bu bedelin ne anlama geldiğine birazdan (Bölüm C) bakacağız — çünkü göründüğü kadar kötü olmayabilir.

3 · SON-İŞLEME

Kararı sonradan dengelemek

Model çoktan eğitildi ve elimizde. Ona hiç dokunmadan, sadece **karar eşiğini gruplara göre ayarlarız.**

Sezgi

Model herkese bir olasılık puanı veriyor. "İşe al" demek için erkeklerde eşiği %50'de tutarken, dezavantajlı grup için biraz düşürürüz — böylece seçim oranları dengelenir. Modeli yeniden eğitmeye gerek yok.

Kullanışlı: modele erişimimiz olmadığında bile (kapalı bir sistem) uygulanabilir.

ÖLÇÜM · SON-İŞLEME

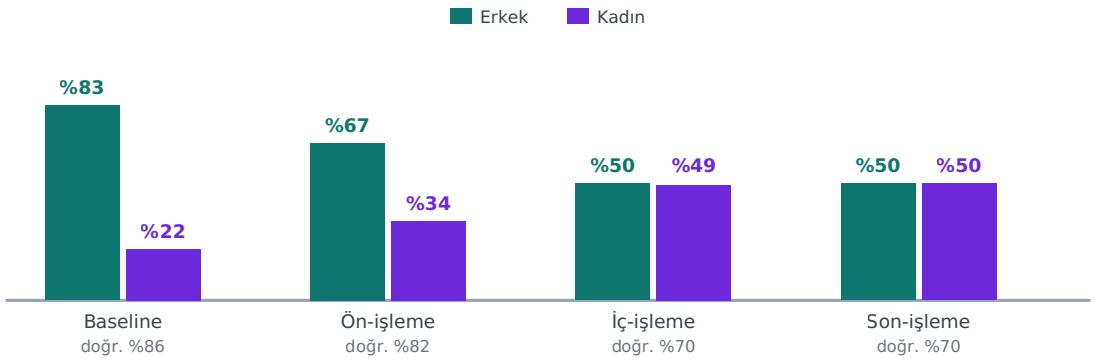
Tam denge

```
Son-işleme (eşik optimizasyonu): erkek %50 · kadın %50 (fark 0.00) · doğruluk %70
```

Seçim oranları tam olarak eşitlendi (fark 0.00), doğruluk yine %70. İç-işlemeye çok benzer bir sonuç — ama farklı bir yoldan, modele hiç dokunmadan.

DÖRDÜ YAN YANA

Her yöntem uçurumu daraltıyor



Soldan sağa: uçurum kapanıyor ama "doğruluk" da (%86→%82→%70) düşüyor. İşte bu, dengenin ta kendisi.

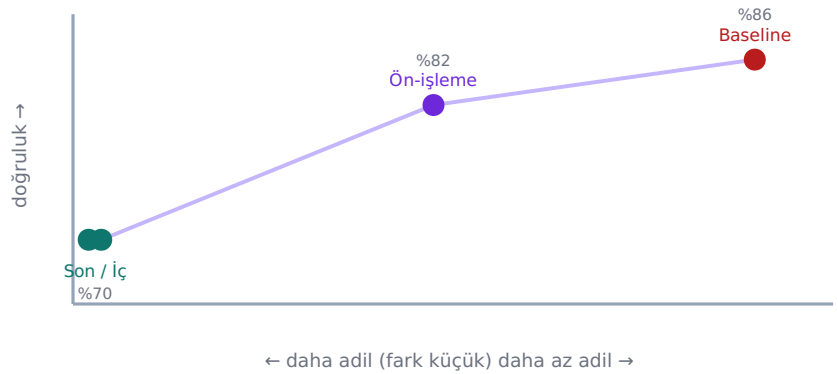
Bölüm C

Bedava Öğle Yemeği Yok

Adalet ile "doğruluk" arasındaki dengeyi anlamak.

DENGEYİ GÖRSELLEŞTİR

Adalet arttıkça doğruluk düşüyor



Sağ üst: yüksek doğruluk, düşük adalet (baseline). Sol alt: yüksek adalet, düşük doğruluk. Her nokta bir **seçim.**

AMA TAM OLARAK NE KAYBETTİK?

"Düşen doğruluk" göründüğü kadar kötü mü?

Buradaki en ince nokta şu (H8'i hatırlayın): bu "doğruluk", **geçmişin önyargılı etiketlerine** göre ölçülüyor. Yani model %86'dan %70'e düşerken, aslında "geçmişi tekrarlama"da daha az başarılı hale geldi.

Yeniden çerçeveleme

Belki de kaybettiğimiz şey gerçek isabet değil, **geçmişe olan sadakattir.** Geçmiş adaletsizse, ondan sapmak bir "hata" değil, bir **düzeltme** olabilir. "Doğruluk" tek başına iyi bir pusula değildir.

PRATİK REHBER

Hangi yöntem, ne zaman?

Yöntem	Ne zaman iyi?	Dikkat
Ön-işleme	Veriye erişimin varsa; ilk ve en genel çözüm.	Kök nedeni her zaman çözmeyebilir.
İç-işleme	Modeli sen eğitiyorsan; en güçlü kontrol.	Teknik olarak karmaşık; doğruluk bedeli yüksek olabilir.
Son-işleme	Modele erişimin yoksa (kapalı/hazır sistem).	"Gruba göre farklı eşik" kendisi tartışmalı olabilir.

Genelde tek bir sihirli yöntem yoktur; bağlama göre seçilir, hatta birleştirilir.

Bölüm D

Asıl Çözüm, Bir Metrik Oyunundan Fazlasıdır

Kod her sorunu çözmez — bazen sorun kodda değildir.

EN GÜÇLÜ MÜDAHALE

Kaynağı düzeltmek: daha iyi veri, daha iyi dünya

Bütün bu yöntemler aynanın yansımasıyla uğraşıyor. Ama en kalıcı çözüm, **aynanın önündeki gerçeği** düzeltmektir.

Örnekler

Daha çeşitli ve dengeli veri toplamak; eksik bırakılan grupları özellikle dahil etmek; "başarı"yı (etiketi) daha adil tanımlamak. Bunlar bir satır kodla değil, kurumsal kararlarla olur — ama etkisi en derinidir.

CESUR AMA GEREKLİ SORU

Bazen doğru cevap: hiç kurmamak

Her sorun bir yapay zekâ ile çözülmek zorunda değil. Özellikle hata bedelinin çok ağır olduğu alanlarda, en sorumlu karar **sistemi hiç devreye almamak** olabilir.

Sormamız gereken

Bu kararı bir makineye vermeli miyiz? Hata birinin hayatını (işini, özgürlüğünü, sağlığını) mahvedecekse ve önyargıyı güvenilir biçimde çözemiyorsak — "daha iyi bir model" değil, belki de "insan kararı" doğru cevaptır.

KİMİN SON SÖZÜ VAR?

Modeli tek karar verici yapmamak

Riskli

Modelin "RED" demesiyle sürecin bitmesi. İnsan devreden çıkınca, önyargı hızla ve itirazsız ölçeklenir.

Daha güvenli

Modeli **karar destek** aracı yapmak: sıralar, önerir, gerekçe sunar — ama nihai kararı, hesap verebilir bir insan verir. Özellikle sınırdaki vakalarda.

Teknik çözümler kadar **kurumsal** çözümler de gerekir: süreç, şeffaflık, hesap verebilirlik ve düzenli denetim.

Bölüm E

Tüm Yolculuğu Birleştirmek

Beş haftada bir denetçinin araç setini kurduk.

NEREDEN NEREYE GELDİK

Adalet denetimi yolculuğu

Hafta	Soru	Kazandığımız araç
H4 · Veri	Önyargı nereden geliyor?	Aynayı sorgulamak
H5 · Model	Model onu tekrar ediyor mu?	Ölçüp kanıtlamak
H7 · Açıklama	Karar neye dayanıyor?	Kara kutuyu açmak
H8 · Metrikler	"Adil" ne demek?	Adaleti tanımlayıp ölçmek
H9 · Azaltma	Nasıl düzeltiriz?	Müdahale etmek — bedeliyle

Artık bir yapay zekâ sistemini baştan sona sorgulayacak donanıma sahipsiniz.

TOPARLAYALIM

Bugün ne öğrendik?

- Önyargıya üç noktada müdahale edebiliriz: **veri, eğitim, karar.**
- **Ön-işleme** (veriyi düzelt): fark 0.61→0.33, doğruluk %86→%82. Hafif ve genel.
- **İç-işleme** (adalet kısıtı): fark →0.01, doğruluk →%70. Güçlü ama pahalı.
- **Son-işleme** (eşik ayarı): fark →0.00, doğruluk →%70. Modele dokunmadan.
- Bir **denge** var — ama "düşen doğruluk" çoğu zaman "geçmişe daha az sadakat"tir.
- En derin çözümler kodda değil: daha iyi veri, insan denetimi, ve "kurmalı mıyız?" sorusu.

SÖZ SİZDE

Tartışma

Birlikte düşünelim

- Modelin doğruluğunu %86'dan %70'e düşürmek "adalet için" kabul edilebilir mi? Bu bir işveren için makul mü?
- "Dezavantajlı grup için karar eşiğini düşürmek" size adil mi geliyor, yoksa yeni bir haksızlık mı? Neden?
- Hangi alanlarda bir yapay zekânın hiç kullanılmaması gerektiğini düşünüyorsunuz?

HAFTA 10 · ÖNİZLEME

Gerçek Vakalar ve Kapanış: Kendi Denetimini Yap

Son hafta iki iş bir arada. Önce öğrendiklerimizi gerçek hayata taşıyoruz: sağlıkta, kredide, adalet sisteminde ve yüz tanımada yaşanmış gerçek yapay zekâ vakaları. Sonra tüm araçları birleştirip kendi denetiminizi nasıl yapacağınızı konuşuyoruz. Denetçi artık sizsiniz.