YAPAY ZEKÂ VE ADALET EĞİTİMİ · HAFTA 10 (SON HAFTA)

Gerçek Vakalar ve Kapanış: Kendi Denetimini Yap

BUGÜNÜN PLANI

Akış

Bölüm	Konu
1	Gerçek dünyadan dört vaka
2	On haftanın haritası ve büyük fikir
3	Bir denetim nasıl yapılır ve örnek denetim
4	Sizin çıktınız: kendi mini denetiminiz
5	Kapanış: sorumluluk ve umut

Bölüm 1

Gerçek Dünyadan Dört Vaka

Bunlar teori değil — yaşandı, ve tanıdık gelecek.

ORTAK ÖRÜNTÜ

Hepsinde aynı hikâye

Dört vaka farklı kıtalarda, farklı sektörlerde. Ama örüntü hep aynı:

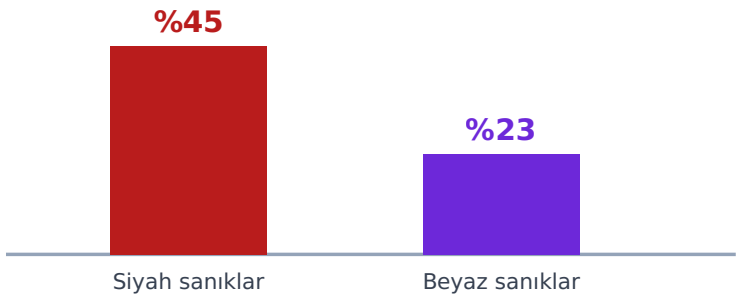
Tanıdık senaryo

Kimse kötü niyetli değildi. Sistem "verimli" ve "tarafsız" sanıldı. Önyargı sessizce veriden geldi, model onu büyük ölçekte tekrar etti, ve **fark edilmesi yıllar aldı** — ta ki biri ölçüp denetleyene kadar. Tıpkı bizim örneğimizdeki gibi.

VAKA 1 · ADALET SİSTEMİ (ABD)

COMPAS: bir algoritma özgürlüğü etkiliyor

COMPAS, bir sanığın tekrar suç işleme "riskini" puanlayıp kefalet ve ceza kararlarında hâkimlere sunuluyordu. ProPublica'nın 2016 incelemesi çarpıcıydı:



Tekrar suç **işlemeyen** sanıklar arasında yanlış "yüksek risk" damgası oranı. Siyahlar, beyazların neredeyse iki katı.

TANIDIK GELİYOR MU? (H8)

Şirket "modelim adil" dedi — ve haksız değildi

Aracı yapan şirket itiraz etti: "Skorum her ırk için **aynı derecede güvenilir**." İki taraf da haklıydı — sadece farklı adalet tanımları kullanıyorlardı.

İmkânsızlık teoremi, gerçek hayatta

Bu, H8'de öğrendiğimiz imkânsızlığın en ünlü örneğidir: grupların taban oranları farklı olduğu için "eşit hata oranı" ile "eşit güvenilirlik" aynı anda sağlanamıyordu. "Hangi adalet?" sorusu bir kod satırında değil, toplumca cevaplanmalı — çünkü bu bir **değer kararıdır.**

VAKA 2 · SAĞLIK (ABD)

200 milyon hastayı etkileyen bir algoritma

Bir algoritma, hangi hastaların ekstra bakıma alınacağını belirliyordu. "İhtiyaç"ı doğrudan ölçemediği için bir **vekil** kullandı: geçmiş sağlık **harcaması.**

Tanıdık gelmeli (H4 · vekil değişken)

Siyah hastalara tarihsel olarak daha az harcama yapıldığından, model "az harcanan = az hasta" diye okudu. Sonuç: aynı risk skorundaki siyah hastalar aslında **%26 daha fazla** kronik hastalık taşıyordu. "Harcama" vekili, tıpkı bizim "kariyer boşluğu" gibi gizli bir eşitsizliği taşıdı.

İYİ HABER (H9 · AZALTMA)

Vekili düzeltmek sorunu büyük ölçüde çözdü

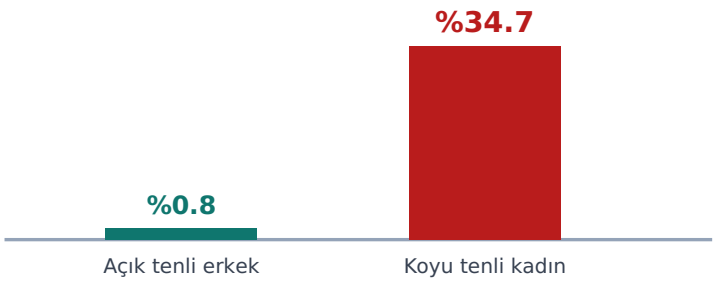
Sorun tespit edilince çözüm netleşti: modeli "harcama"yı değil doğrudan **sağlık durumunu** tahmin edecek şekilde yeniden kurmak.

Sonuç

Bu düzeltmeyle, ekstra bakıma alınması gereken siyah hastaların oranı ciddi biçimde arttı. Tıpkı H9'da gördüğümüz gibi: **önyargı ölçülebilir olduğunda, düzeltilebilir de.** Sorun modelde değil, seçtiğimiz vekildeydi.

VAKA 3 · YÜZ TANIMA

"Gender Shades": sistem kimi göremiyor?



Cinsiyet tahmininde hata oranı. Açık tenli erkeklerde ≤%0.8, koyu tenli kadınlarda %34.7'ye kadar (en koyu tenlilerde neredeyse %47).

TANIDIK GELMELİ (H4 · TEMSİL + KESİŞİM)

İki dezavantaj birleşince

Neden koyu tenli kadınlar?

Bu sistemler çoğunlukla açık tenli erkek fotoğraflarıyla eğitilmişti (temsil önyargısı). Az gördüğü yüzleri iyi öğrenemedi. İki dezavantaj (kadın + koyu tenli) üst üste binince zarar katlandı — tam da H4'teki kesişim etkisi.

Sonuç ve değişim

Bu tür sistemler poliste kullanıldığında **haksız tutuklamalara** yol açtı. Ama çalışma büyük yankı uyandırdı: şirketler sistemlerini gözden geçirdi, bazıları yüz tanımayı polise satmayı durdurdu. **Bir denetim, bir sektörü değiştirdi.**

VAKA 4 · FİNANS

Kredi kartı: açıklanamayan karar

2019'da, benzer (hatta daha iyi) profildeki kadınlara çok daha düşük kredi limiti verildiği iddiaları büyüdü. Kartı veren kurum "cinsiyeti kullanmıyoruz" dedi — ama H4'ten biliyoruz ki bu, adil olduğu anlamına gelmez.

Asıl sorun (H7 · kara kutu)

En büyük sıkıntı, farkın kendisi kadar **kimsenin nedenini açıklayamamasıydı.** Düzenleyici incelemesinde eldeki veriyle yasa dışı ayrımcılık kanıtlanamadı; ama vaka net gösterdi: **açıklanamayan bir sistemi ne denetlemek ne de ona güvenmek mümkün.**

HEPSİNİ BAĞLAYALIM

Her vaka, öğrendiğimiz bir kavram

Vaka	Ana sorun	Kurstaki kavram
COMPAS (adalet)	Çelişen adalet tanımları	İmkânsızlık · H8
Sağlık algoritması	"Harcama" vekili	Vekil değişken · H4
Yüz tanıma	Dengesiz eğitim verisi	Temsil önyargısı · H4
Kredi kartı	Açıklanamayan karar	Kara kutu · H7

Öğrendiğiniz her kavramın, gerçek dünyada milyonlarca insanı etkileyen bir karşılığı var.

Bölüm 2

On Haftayı Birleştirmek: Kendi Denetimin

Dağınık araçlar, tek bir güç: denetim.

NEREDEN NEREYE GELDİK

On haftanın haritası

Hafta	Öğrendiğimiz
H1–H3	YZ nedir, günlük hayat, ve Python'a giriş.
H4 · Veri	Önyargı veriden gelir; YZ verisinin aynasıdır.
H5 · Sinir ağları	Bir makine nasıl "öğrenir": nöron, katman, gradyan inişi.
H6 · LLM'ler	ChatGPT nasıl çalışır: token, dikkat, Transformer.
H7 · Açıklama	Kara kutuyu açıp "neden" sorusunu sormak.
H8 · Metrikler	"Adil" tek şey değil; tanımlar çelişebilir.
H9 · Azaltma	Önyargı ölçülebilirse azaltılabilir — bir bedelle.

On haftanın tek cümlesi

Yapay zekâ — basit modelden dev dil modeline — verisinin bir **aynasıdır**: sıradan bir makine, ama asla tarafsız değil.
Ve en önemlisi: **sorgulanabilir.**

DENETİMİN KALBİ

Bir yapay zekâya soracağınız 5 soru

1 · Veri

Bu veri kimden geldi? Kimi eksik bıraktı? Gizli vekil değişkenler var mı?

2 · Model

Gruplar arasında farklı mı davranıyor? Önyargıyı tekrar mı ediyor?

3 · Açıklama

Kararlar neye dayanıyor? Model en çok neye bakıyor?

4 · Metrikler

Hangi adalet tanımı, ne kadar ihlal ediliyor?

5 · Azaltma & Öneri

Nasıl düzeltilebilir? Bedeli ne? İnsan denetimi var mı? Bu sistem hiç kurulmalı mı?

BAŞTAN SONA ÖRNEK

Tanıdık modelimizi denetleyelim

Sistem

Bir işe alım yapay zekâsı, adayları geçmiş verilere bakarak "işe al / alma" diye sınıflıyor. Karar bedeli yüksek: birinin iş bulup bulamaması. Beş soruyu sırayla soralım. (Rakamların hepsi kursta gerçek kodla üretildi.)

BULGULAR (SORU 1–3)

Veri, model ve açıklama

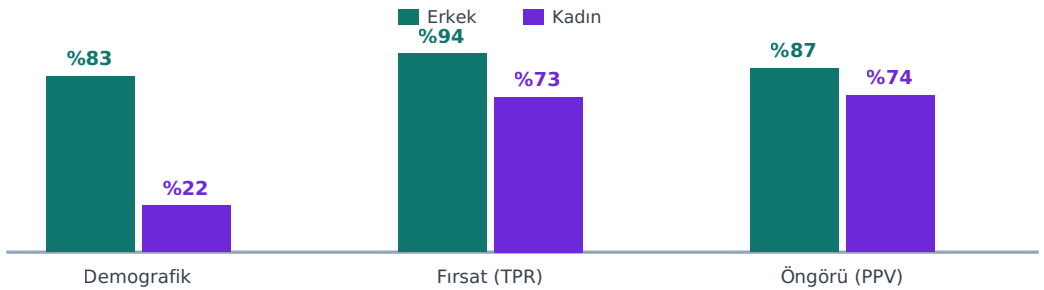
```
VERİ: geçmiş işe alınma erkek %77 · kadın %23; "kariyer boşluğu" bir vekil MODEL: seçim oranı erkek %83 · kadın %22 (geçmişi tekrarladı) AÇIKLAMA: en önemli özellik = cinsiyet; Zeynep %39 → RED, "erkek" olsa %91 → KABUL
```

Ara sonuç

Ayna zaten çarpık, model onu tekrarladı, ve kararların en güçlü belirleyicisi cinsiyet. Nitelikli bir kadın adayı asıl eleyen, cinsiyetiydi.

BULGU (SORU 4 · METRİKLER)

Hangi mercekten baksak, uçurum var



Üç adalet tanımının üçünde de kadınlar geride; demografik eşitlik 4/5 kuralını (0.26) açıkça kırıyor.

ÖNERİLER (SORU 5) → RAPOR ÖZETİ

İşte bir denetim raporu

Sonuç

Sistem, kadın adaylara karşı üç adalet tanımında da sistematik ayrımcılık yapıyor; kararların en güçlü belirleyicisi cinsiyet. **Mevcut haliyle kullanıma uygun değildir.**

Öneriler

- Veriyi yeniden dengele (ön-işleme) ve vekil değişkenleri incele.
- Bir adalet tanımını paydaşlarla **açıkça** seç; bedelini kabul et.
- Modeli tek karar verici yapma — insan denetimi ve itiraz yolu ekle.
- Düzenli yeniden denetle; kararları açıklanabilir tut.

Bölüm 3

Sizin Çıktınız: Kendi Mini Denetiminiz

Öğrendiğiniz her şeyi kullanma zamanı.

UYGULAMA

Göreviniz

Bir yapay zekâ sistemi seçin ve denetleyin

Gerçek ya da kurgusal bir sistem seçin. Beş soruyu sorun, bulabildiğiniz kanıtları toplayın (rakam yoksa mantıksal tartışın) ve kısa bir **adalet raporu** yazın (1–2 sayfa).

Kod yazmanız **şart değil.** Asıl değerlendirdiğimiz beceri: doğru soruları sormak ve önyargının nereye saklandığını görebilmek.

NEREDEN BAŞLARIM?

Denetlenebilecek sistem fikirleri

Günlük hayattan

- Sosyal medya içerik önerileri
- Kredi / kredi kartı başvurusu
- İşe alım özgeçmiş tarama
- Sınav / üniversite yerleştirme

Daha kritik alanlar

- Sağlıkta triyaj / öncelik
- Yüz tanıma / güvenlik
- Sosyal yardım hak ediş
- ChatGPT gibi bir sohbet botu

İpucu: sizi ya da yakınınızı doğrudan etkileyen bir sistem seçin — en iyi denetimler oradan çıkar.

NE GEREKİYOR?

İyi bir denetçinin araçları teknik değildir

Biraz kod gördük ama asıl becerileriniz bunlar değil. İyi bir denetçiyi yapan şeyler çok daha insani:

Merak & şüphecilik

"Bilgisayar dedi" ile yetinmemek; "ama neden ve kimin için?" diye sormak.

Empati & iletişim

Kimin zarar gördüğünü fark etmek ve bulguyu herkesin anlayacağı dile çevirmek.

Bunların hepsi zaten sizde var. Kurs sadece onlara bir yön verdi.

Bölüm 4

Kapanış: Sorumluluk ve Umut

Denetçi artık sizsiniz.

NEDEN BU BECERİ ÖNEMLİ?

Bu sistemler sizin hakkınızda karar veriyor

Yapay zekâ artık kimin işe alınacağına, kimin kredi alacağına, kimin hangi hizmete erişeceğine karar veriyor. Ve gördük ki bu sistemler, kimse sorgulamazsa geçmişin haksızlıklarını sessizce sürdürüyor.

Sizin farkınız

Önyargının en çok etkilediği gruplardan gelen bir bakış, onu görmek için en keskin gözdür. Sizin sorularınız, başkalarının kaçırdığı adaletsizliği yakalayabilir. **Bu masada sizin sesinize ihtiyaç var.**

YOLCULUK BURADA BİTMİYOR

Öğrenmeye devam etmek isterseniz

Araçlar (açık ve ücretsiz)

- Fairlearn, IBM AI Fairness 360 (adalet ölçüm kütüphaneleri)
- Google "What-If Tool" (görsel model inceleme)

Okuma & topluluk

- Cathy O'Neil — "Weapons of Math Destruction"
- Algorithmic Justice League (J. Buolamwini)

Alan sürekli değişiyor — merakınızı canlı tutmak en iyi yatırımdır.

SON ÖZET

Artık bunları biliyorsunuz

- Yapay zekânın **ne olduğunu** ve nasıl çalıştığını — basit modelden sinir ağlarına ve LLM'lere.
- Önyargının nereden geldiğini ve modelin (derin bile olsa) onu nasıl tekrarladığını.
- Bir kararı **açıklamayı**, adaleti **ölçmeyi** ve önyargıyı **azaltmayı.**
- Bu sorunların gerçek dünyada milyonlarca insanı etkilediğini.
- Bütün bunları bir **denetime** dönüştürmeyi — ve o denetçinin siz olduğunu.

Son bir cümle

Yapay zekâyı durduramayız — ama onu **hesap verebilir** kılabiliriz.
Ve bunu yapacak kişiler, tam da **sizin gibi soru soran insanlardır.**

YAPAY ZEKÂ VE ADALET EĞİTİMİ

Teşekkürler

On hafta boyunca gösterdiğiniz merak ve emek için teşekkürler. Bugünden itibaren yapay zekânın karşısında pasif bir kullanıcı değil, soru soran ve hesap sorabilen bir denetçisiniz. Sıra sizde.